







Aprendizado por Reforço

Samuel e Larissa



Introdução

O desafio foi ensinar a IA a jogar o jogo do dinossauro do Chrome, mas sem dar a ela as regras. Ela teria que aprender por si só utilizando da técnica de Aprendizado por Reforço (Reinforcement Learning).




O que a IA vê?

Demos a ela um vetor de 4 valores. Esses são os “sensores” dela.



velocidade do jogo: v



$$\frac{x}{v}$$

2

Tempo até o impacto

Isso diz à IA: “Você tem X segundos para bater”

3

Tipo do Obstáculo

Se é um cacto ou um pterodáctilo

1


Altura do dinossauro

Para saber se está no ar ou no chão.

4

Altura do Obstáculo


Para saber se deve pular ou agachar.



O que a IA pode fazer?


Ela pode escolher entre três ações:

- 0 Correr (não fazer nada)
- 1 Agachar
- 2 Pular




A cada passo que o dinossauro sobrevive, a IA ganha **+1** ponto, incentivando sua sobrevivência.

Se o jogo acabar (bater num obstáculo), a “recompensa” é **-10**.






Algoritmo utilizado:



PPO (Proximal Policy Optimization)

O nome vem da ideia de que a IA não deve mudar o seu comportamento (política) drasticamente de uma vez só.

```
model = PPO("MlpPolicy", env, verbose=1, tensorboard_log=LOG_DIR, learning_rate=0.0003, ent_coef=0.01)
```



MLP é de **Multi-Layer Perceptron**, a rede neural clássica, já que a entrada são apenas números. Outra opção seria CnnPolicy, que usa Redes Convolucionais.


Taxa de aprendizado
Se alta demais, A IA oscila e não aprende.
Se baixa demais, A IA é muito lenta para evoluir.

Coefficiente de Entropia
Mede o “caos” ou a incerteza. Um coeficiente alto força a IA a explorar mais.

Vantagem = Resultado Real - Valor do Crítico (Expectativa)

Ator X Crítico

tempo curto e
obstáculo baixo




correr = 0.1

agachar = 0.05

pular = 0.85


situação de perigo
iminente que requer pulo

situação perigosa, alta
chance de perder



-0.2
péssima
situação,
prevejo morte
iminente

tempo curto e
obstáculo baixo





O que a IA vê?



Distância Vertical

A diferença de altura entre o pássaro e o centro do buraco do cano. Isso diz à IA se ela precisa subir ou descer.




Velocidade Vertical

Diz se o pássaro está a cair rápido ou a subir (impulso).



Altura do pássaro

Para saber se está perto de bater no teto ou no chão.



Distância Horizontal

Quão longe está o próximo cano?

O que a IA pode fazer?


Ela pode escolher entre apenas duas ações:



Não fazer nada (deixar a gravidade atuar)



Bater asas (dar um impulso para cima)



Recompensas:

Sobreviver:

Ganha +0.1 a
cada frame vivo.

Passar Cano:

Ganha +1.0 (o
grande objetivo).

Morrer: Recebe

-1.0 se tocar no
chão ou num cano.

Qual foi a diferença?

Arquitetura da Rede Neural

No Flappy Bird foi usada a arquitetura padrão da PPO (64x64), uma vez que a decisão é apenas binária.

Coeficiente de Entropia

O Flappy Bird não precisou de coeficiente de entropia, porque a gravidade mata você em 2 segundos se não fizer nada. A "punição por inércia" é imediata.

Estratégia de Salvamento


CheckpointCallback X EvalCallback


Salva periodicamente (a cada 100.000 passos).	Salva apenas o melhor (verificando a cada 10.000)
--	--

Duração do Treino

(Dino) 1.000.000 X (Flappy) 5.000.000

É mais seguro um treino com maior duração uma vez que usamos o EvalCallback.






Mais aplicações

O aprendizado por reforço não é utilizado apenas em jogos.

No contexto de um carro autônomo, por exemplo:

Sensores



O carro está chegando a um cruzamento e o sinal fica amarelo. O ator tem um dilema:

Acelerar para passar ou **Parar bruscamente?**

Crítico: “Nesta velocidade com chuva, tentar passar é uma péssima ideia. O Valor desta situação é baixo (perigoso).”

Ator: “Vou Acelerar!”

Consequência: O carro passa no vermelho e quase bate. O sistema recebe uma penalidade.

Algoritmo: Calcula a “Vantagem”:

Vantagem = Multa (-100) - Valor do Crítico (-50))